

课程项目研究提案 (Proposal)

项目名称：基于冲突检测与反思机制的长期记忆 Agent 研究与实现

所属课程：自然语言处理

一、选题背景与意义

选题：长期记忆对话 Agent (Long-Term Memory Agent)

研究意义：

大语言模型在交互中通常表现为“无状态”。本项目旨在实现一个能够跨会话、跨时间记住用户信息，并能处理信息冲突与知识更新的智能体。这不仅能提升用户体验的连续性，也是构建个性化 AI 助手的关键技术方向。

探索方向：

本项目将重点探索以下两个方向的组合：

- 记忆更新 (Memory Update)**：对比“只追加”与“冲突检测后更新/合并”的效果（参考 Mem0 思路）。
- 反思机制 (Reflection)**：加入周期性 Reflection 生成高阶记忆，以提升对用户意图的长程理解（参考 Generative Agents 思路）。

二、组队情况

- 计鑫楷 231880380
- 张嘉杰 231880239
- 张闻曦 231880099

三、研究计划与时间表

根据课程关键时间点，计划安排如下：

阶段	时间跨度	关键任务与产出
第一阶段： 文献与环境	2026.05.10 - 2026.05.17	阅读 <i>Generative Agents</i> 与 <i>Mem0</i> 等必读文献；完成 <code>vLLM</code> 环境搭建，部署 <code>Qwen2.5-3B-Instruct-AWQ</code> 底座模型。
第二阶段： 基线系统开发	2026.05.18 - 2026.05.25	实现 <code>Memory Store</code> (FAISS) 和基础的 <code>writer</code> 与 <code>Retriever</code> ；建立 <i>No-memory</i> 与 <i>Vanilla RAG</i> 基线对照组。
第三阶段： 核心功能与实验	2026.05.26 - 2026.06.03	实现冲突检测更新逻辑与反思机制；在小样本上完成初步调试，准备 Milestone 进展报告。
第四阶段： 全量评测与分析	2026.06.04 - 2026.06.12	使用助教提供的 LoCoMo 评测集进行全量评测；利用 <code>LLM-as-Judge</code> (如 DeepSeek V4 Flash) 进行自动打分；进行消融实验与 Bad Case 分析。

阶段	时间跨度	关键任务与产出
第五阶段： 总结与交付	2026.06.13 - 2026.06.17	撰写最终实验报告（正文 8-9 页，ACL 模板）；整理代码并准备答辩 PPT。

四、 预期技术路线

- 1. 底座模型： Qwen2.5-3B-Instruct-AWQ。
- 2. 存储机制： 利用 BAAI/bge-small-zh-v1.5 生成向量，存储于 FAISS。
- 3. 记忆管理：
 - 提取： 利用 LLM 总结对话为独立的“记忆单元”。
 - 更新： 当新记忆与旧记忆在语义空间高度相关但逻辑冲突时，通过 Prompt 触发更新机制。
- 4. 评测指标： QA 准确率（单/跨会话回忆、时间推理、信息更新）、响应时间及调用成本。